Анализ результатов А/В-теста интернет-магазина.

Нужна приоритизировать гипотезы, запустить А/В-тест и проанализировать результаты.

- Первый этап изучение общий информации.
- Второй этап предобработка данных.
- Третий этап приоритизация гипотез.
- Четвертый этап запустить А/В-тест и проверит гипотезы, анализ результатов.
- Пятый этап общий вывод.

Среди данных у нас есть гипотез по увеличению выручки интернет-магазина с указанными параметрами, идентификаторы заказа, идентификаторы пользователя, выручка заказа, количество пользователей. Данные разбиты на две группы А и В.

Изучение общий информации.

```
In [1]: import pandas as pd
  import datetime as dt
  import numpy as np
  import matplotlib.pyplot as plt
  from pandas.plotting import register_matplotlib_converters
  import warnings
  import scipy.stats as stats
```

```
In [2]: efforts = pd.read_csv('/datasets/hypothesis.csv')
   pd.options.display.max_colwidth = 130
   display(efforts)
```

	Hypothesis	Reach	Impact	Confidence	Efforts
0	Добавить два новых канала привлечения трафика, что позволит привлекать на 30% больше пользователей	3	10	8	6
1	Запустить собственную службу доставки, что сократит срок доставки заказов	2	5	4	10
2	Добавить блоки рекомендаций товаров на сайт интернет магазина, чтобы повысить конверсию и средний чек заказа	8	3	7	3
3	Изменить структура категорий, что увеличит конверсию, т.к. пользователи быстрее найдут нужный товар	8	3	3	8
4	Изменить цвет фона главной страницы, чтобы увеличить вовлеченность пользователей	3	1	1	1
5	Добавить страницу отзывов клиентов о магазине, что позволит увеличить количество заказов	3	2	2	3
6	Показать на главной странице баннеры с актуальными акциями и распродажами, чтобы увеличить конверсию	5	3	8	3
7	Добавить форму подписки на все основные страницы, чтобы собрать базу клиентов для email-рассылок	10	7	8	5
8	Запустить акцию, дающую скидку на товар в день рождения	1	9	9	5

```
In [3]: orders = pd.read_csv('/datasets/orders.csv')
display(orders.head())
```

	transactionId	visitorId	date	revenue	group
0	3667963787	3312258926	2019-08-15	1650	В
1	2804400009	3642806036	2019-08-15	730	В
2	2961555356	4069496402	2019-08-15	400	Α
3	3797467345	1196621759	2019-08-15	9759	В
4	2282983706	2322279887	2019-08-15	2308	В

```
In [4]: visitors = pd.read_csv('/datasets/visitors.csv')
    display(visitors.head())
```

	date	group	visitors
0	2019-08-01	А	719
1	2019-08-02	А	619
2	2019-08-03	А	507
3	2019-08-04	А	717
4	2019-08-05	А	756

Для удобства нужно привести название столбцов в таблице efforts к нижнему регистру, проверить типы данных, следует изучить наличие пропусков и дубликатов.

Предобработка данных.

```
In [5]: print(efforts.isna().sum())
       print('Количество дубликатов:', efforts.duplicated().sum())
       Hypothesis 0
       Reach 0 Impact 0
       Confidence 0
       Efforts 0
       dtype: int64
       Количество дубликатов: 0
In [6]: print(orders.isna().sum())
       print('Количество дубликатов:', orders.duplicated().sum());
       transactionId 0
       visitorId
       date
       revenue
       group
       dtype: int64
       Количество дубликатов: 0
In [7]: print(visitors.isna().sum())
       print('Количество дубликатов:', visitors.duplicated().sum());
       date
                  0
       group
                  0
       visitors 0
```

У столбцов с датами изменены типы на более подходящие, пропусков и дубликатов нет.

Приоритизация гипотез.

dtype: int64

16.2

```
In [9]: efforts['ICE'] = efforts['impact'] * efforts['confidence'] / efforts['efforts']
        print(efforts[['hypothesis', 'ICE']].sort values(by='ICE', ascending=False).head(5).roun
                     hypothesis \
                                                                Запустить акцию, дающую скидку н
        а товар в день рождения
                     Добавить два новых канала привлечения трафика, что позволит привлекать на 3
        0% больше пользователей
                       Добавить форму подписки на все основные страницы, чтобы собрать базу клие
        нтов для email-рассылок
                   Показать на главной странице баннеры с актуальными акциями и распродажами, чт
        обы увеличить конверсию
        2 Добавить блоки рекомендаций товаров на сайт интернет магазина, чтобы повысить конверс
        ию и средний чек заказа
             ICE
        8 16.20
        0 13.33
        7 11.20
        6 8.00
        2 7.00
In [10]: efforts['RICE'] = efforts['reach'] * efforts['impact'] * efforts['confidence'] / efforts
        print(efforts[['hypothesis', 'RICE']].sort values(by='RICE', ascending=False).head(5))
                     hypothesis \
                       Добавить форму подписки на все основные страницы, чтобы собрать базу клие
        нтов для email-рассылок
        2 Добавить блоки рекомендаций товаров на сайт интернет магазина, чтобы повысить конверс
        ию и средний чек заказа
                     Добавить два новых канала привлечения трафика, что позволит привлекать на 3
        0% больше пользователей
                  Показать на главной странице баннеры с актуальными акциями и распродажами, чт
        обы увеличить конверсию
                                                                Запустить акцию, дающую скидку н
        а товар в день рождения
            RICE
        7 112.0
           56.0
           40.0
            40.0
```

В топ пять входят гипотезы:

- Добавить два новых канала привлечения трафика, что позволит привлекать на 30% больше
- Добавить блоки рекомендаций товаров на сайт интернет магазина, чтобы повысить конверсию и средний чек заказа.
- Показать на главной странице баннеры с актуальными акциями и распродажами, чтобы увеличить конверсию.
- Добавить форму подписки на все основные страницы, чтобы собрать базу клиентов для emailрассылок.
- Запустить акцию, дающую скидку на товар в день рождения.

Но их порядок разница так как в RICE еще учитывается охват пользователей(Reach). У гипотезы "Добавить форму подписки на все основные страницы" Reach больше чем у "Добавить два новых канала привлечения трафика" и "Запустить акцию, дающую скидку на товар в день рождения" поэтому в RICE она занимает первое место, а в ICE "Запустить акцию, дающую скидку на товар в день рождения" занимает первую позицию.

Проверка гипотез и анализ результатов.

```
In [11]: datesGroups = orders[['date', 'group']].drop duplicates()
         ordersAggregated = datesGroups.apply(
             lambda x: orders[
                np.logical and(
                     orders['date'] <= x['date'], orders['group'] == x['group']</pre>
             ].agg(
                     'date': 'max',
                     'group': 'max',
                     'transactionId': 'nunique',
                     'visitorId': 'nunique',
                     'revenue': 'sum',
                 }
             ),
             axis=1,
         ).sort values(by=['date', 'group'])
         visitorsAggregated = datesGroups.apply(
            lambda x: visitors[
                np.logical and(
                    visitors['date'] <= x['date'], visitors['group'] == x['group']</pre>
             ].agg({'date': 'max', 'group': 'max', 'visitors': 'sum'}),
         ).sort values(by=['date', 'group'])
         cumulativeData = ordersAggregated.merge(
            visitorsAggregated, left on=['date', 'group'], right on=['date', 'group']
         cumulativeData.columns = [
            'date',
             'group',
             'orders',
             'buyers',
             'revenue',
             'visitors',
```

```
| cumulativeRevenueB = cumulativeData[cumulativeData['group'] == 'B'][['date', 'revenue', 'o cumulativeRevenueA = cumulativeData[cumulativeData['group'] == 'A'][['date', 'revenue', 'or # Строим график выручки группы A plt.plot(cumulativeRevenueA['date'], cumulativeRevenueA['revenue'], label='A') # Строим график выручки группы B plt.plot(cumulativeRevenueB['date'], cumulativeRevenueB['revenue'], label='B') plt.legend() plt.axis([pd.to_datetime("2019-08-01"), pd.to_datetime('2019-08-31'), 0, 7000000]) plt.title('График кумулятивной выручки по группам') plt.xlabel('Дата проведения эксперемента') plt.ylabel('Выручка заказа') plt.gcf().set_size_inches(8, 4) plt.show(); #№1
```



Выручка обеих групп растет, группа В ближе к середине графика начинает опережать группу А и чуть позже делает резкий скачек, скорее всего это обусловлено большими заказами с аномальна высокой выручкой, либо высокое число заказов в выборке.

```
In [12]: plt.plot(cumulativeRevenueA['date'], cumulativeRevenueA['revenue']/cumulativeRevenueA['o plt.plot(cumulativeRevenueB['date'], cumulativeRevenueB['revenue']/cumulativeRevenueB['o plt.axis([pd.to_datetime("2019-08-01"), pd.to_datetime('2019-08-31'), 2000, 15000]) plt.legend() plt.title('График кумулятивного среднего чека по группам') plt.xlabel('Дата проведения эксперимента') plt.ylabel('Средняя выручка заказа') plt.gcf().set_size_inches(8, 4) plt.show();
#N2
```



Средний чек не равномерен и группа А и группа В имеют очень резкие колебания, требуется дополнительный анализ выбросов которые искажают результаты.



По графику относительного изменения кумулятивного среднего чека видны различия, несколько дней сильно менялись данные их нужна проверять на аномалии, выбросы и крупные заказы.

```
plt.title('График кумулятивного среднего количества заказов')
plt.xlabel('Дата проведения эксперимента')
plt.ylabel('Средняя количества заказов')
plt.axis([pd.to_datetime("2019-08-01"), pd.to_datetime('2019-08-31'), 0.028, 0.04])
plt.gcf().set_size_inches(8, 4)
plt.show();
```



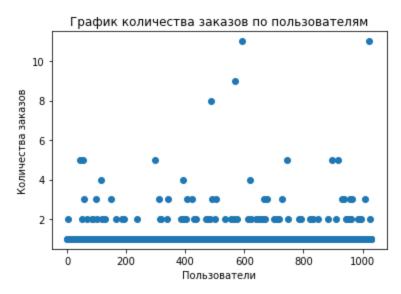
Количество заказов в обеих группах к середине начинает быть стабильной. Группа В по мере накопления данных становится выше группы А и держится на этом уровне до конца теста.

График относительного изменения кумулятивного среднего количества заказов на посетителя группы В к группе A



График различия среднего количества заказов между группами сообщает, что результаты группы В лучше группы А, на середине графика есть небольшой подъем возможна из за аномального количества заказов или выбросов.

11
11
9
8
5
5
5
5
5
5



Есть много пользователей с 2-5 заказами.

```
In [17]: print(np.percentile(ordersByUsers['orders'], [90, 95, 99]))
#Nº7
```

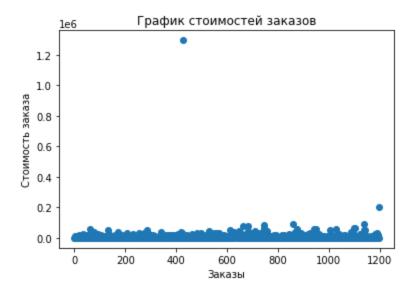
[1. 2. 4.]

Не больше 5% пользователей совершили больше двух заказов и не больше 1% пользователей совершили больше четырех заказов. За аномалию возьмем 3 заказами.

```
In [18]: display(orders.sort_values(by='revenue', ascending=False).head(10))

x_values = pd.Series(range(0, len(orders['revenue'])))
plt.scatter(x_values, orders['revenue'])
plt.title('График стоимостей заказов')
plt.xlabel('Заказы')
plt.ylabel('Стоимость заказа')
plt.show();
#№8
```

	transactionId	visitorId	date	revenue	group
425	590470918	1920142716	2019-08-19	1294500	В
1196	3936777065	2108080724	2019-08-15	202740	В
858	192721366	1316129916	2019-08-27	93940	Α
1136	666610489	1307669133	2019-08-13	92550	Α
744	3668308183	888512513	2019-08-27	86620	В
682	1216533772	4266935830	2019-08-29	78990	В
662	1811671147	4266935830	2019-08-29	78990	А
743	3603576309	4133034833	2019-08-09	67990	Α
1103	1348774318	1164614297	2019-08-12	66350	А
1099	316924019	148427295	2019-08-12	65710	А



Есть выбросы в районе 200 000 рублей и в 1 200 000 рублей.

```
In [19]: print(np.percentile(orders['revenue'], [90, 95, 99]))
#Nº9
[18168. 28000. 58233.2]
```

Не более, чем у 5% заказов чек дороже 28000. И не больше, чем у 1% заказов - дороже 58233 рублей. За аномалии возьмем 50000.

```
ordersBDaily = (
            orders[orders['group'] == 'B'][['date', 'transactionId', 'visitorId', 'revenue']]
             .groupby('date', as index=False)
             .agg({'visitorId': pd.Series.nunique, 'revenue': 'sum'})
         ordersBDaily.columns = ['date', 'ordersPerDateB', 'revenuePerDateB']
In [21]: cumulativeRevenueA.columns = ['date', 'revenueCummulativeA','ordersCummulativeA']
         cumulativeRevenueB.columns = ['date', 'revenueCummulativeB','ordersCummulativeB']
In [22]: visitorsADaily = visitors[visitors['group'] == 'A'][['date', 'visitors']]
        visitorsADaily.columns = ['date', 'visitorsPerDateA']
        visitorsBDaily = visitors[visitors['group'] == 'B'][['date', 'visitors']]
         visitorsBDaily.columns = ['date', 'visitorsPerDateB']
In [23]: visitorsACummulative = visitorsADaily.apply(
            lambda x: visitorsADaily[visitorsADaily['date'] <= x['date']].agg(</pre>
                {'date': 'max', 'visitorsPerDateA': 'sum'}
             ),
            axis=1,
         visitorsACummulative.columns = ['date', 'visitorsCummulativeA']
         visitorsBCummulative = visitorsBDaily.apply(
             lambda x: visitorsBDaily[visitorsBDaily['date'] <= x['date']].agg(</pre>
                 {'date': 'max', 'visitorsPerDateB': 'sum'}
             ),
            axis=1,
         visitorsBCummulative.columns = ['date', 'visitorsCummulativeB']
         #print(visitorsBCummulative)
In [24]: data = (
            ordersADaily.merge(
                ordersBDaily, left on='date', right on='date', how='left'
             .merge(cumulativeRevenueA, left on='date', right on='date', how='left')
             .merge(cumulativeRevenueB, left on='date', right on='date', how='left')
            .merge(visitorsADaily, left on='date', right on='date', how='left')
             .merge(visitorsBDaily, left on='date', right on='date', how='left')
             .merge(visitorsACummulative, left on='date', right on='date', how='left')
             .merge(visitorsBCummulative, left on='date', right on='date', how='left')
In [25]: ordersByUsersA = (
            orders[orders['group'] == 'A']
             .groupby('visitorId', as index=False)
             .agg({'transactionId' : pd.Series.nunique})
         ordersByUsersA.columns = ['user id', 'orders']
         ordersByUsersB = (
         orders[orders['group'] == 'B']
             .groupby('visitorId', as index=False)
             .agg({'transactionId' : pd.Series.nunique})
         ordersByUsersB.columns = ['user id', 'orders']
         pd.Series(0, index=np.arange(data['visitorsPerDateA'].sum()-len(ordersByUsersA['orders']
         [ordersByUsersA['orders'],
```

```
In [26]: sampleA = pd.concat(
                 ordersByUsersA['orders'],
                 pd.Series (
                     0,
                     index=np.arange(
                         data['visitorsPerDateA'].sum() - len(ordersByUsersA['orders'])
                     ),
                     name='orders',
                 ),
             ],
             axis=0,
         sampleB = pd.concat(
                 ordersByUsersB['orders'],
                 pd.Series (
                     0,
                     index=np.arange(
                         data['visitorsPerDateB'].sum() - len(ordersByUsersB['orders'])
                     ),
                     name='orders',
                 ),
             ],
             axis=0,
```

Проверим статистическую значимость различий в среднем количестве заказов на посетителя по «сырым» данным.

Сформулируем гипотезы:

- Нулевая: различий в среднем количестве заказов между группами нет.
- Альтернативная: различия в среднем между группами есть.

```
In [27]: #статистическая значимость различий в среднем количестве заказов на посетителя print('Значения p-value:', "{0:.3f}".format(stats.mannwhitneyu(sampleA, sampleB)[1])) print('Различие в средних:', "{0:.3f}".format(sampleB.mean() / sampleA.mean() - 1)) #№10
```

Значения p-value: 0.017 Различие в средних: 0.138

Вывод: По «сырым» данным различий в среднем числе заказов групп A и B есть. Разница между сегментами 13%.

Теперь проверим статистическую значимость различий в среднем чеке между группами по «сырым» данным.

Сформулируем гипотезы:

- Нулевая гипотеза: различий в среднем чеке между группами нет.
- Альтернативная гипотеза: различия в среднем чеке между группами есть.

```
In [28]: print('Значения p-value:', '{0:.3f}'.format(stats.mannwhitneyu(orders[orders['group']==', print('Различие в средних:', '{0:.3f}'.format(orders[orders['group']=='B']['revenue'].me
```

```
Значения p-value: 0.729
Различие в средних: 0.259
```

Вывод: Причин отвергать нулевую гипотезу и считать, что в среднем чеке есть различия, нет. Разница между сегментами 26%.

```
In [29]: usersWithManyOrders = pd.concat(
             ordersByUsersA[ordersByUsersA['orders'] > 3]['user id'],
            ordersByUsersB[ordersByUsersB['orders'] > 3]['user id'],
         ],
         axis=0,
         usersWithExpensiveOrders = orders[orders['revenue'] > 50000]['visitorId']
         abnormalUsers = (
            pd.concat([usersWithManyOrders, usersWithExpensiveOrders], axis=0)
            .drop duplicates()
            .sort values()
         print(abnormalUsers.head(5))
        1099 148427295
        18
               199603092
        23
               237748145
        1137 759473111
        949
               887908475
        dtype: int64
In [30]: sampleAFiltered = pd.concat(
                 ordersByUsersA[
                     np.logical not(ordersByUsersA['user id'].isin(abnormalUsers))
                ]['orders'],
                pd.Series(
                     0,
                     index=np.arange(
                         data['visitorsPerDateA'].sum() - len(ordersByUsersA['orders'])
                     name='orders',
                ),
             ],
             axis=0,
         sampleBFiltered = pd.concat(
            Γ
                 ordersByUsersB[
                     np.logical not(ordersByUsersB['user id'].isin(abnormalUsers))
                ]['orders'],
                 pd.Series(
                     0,
                     index=np.arange(
                         data['visitorsPerDateB'].sum() - len(ordersByUsersB['orders'])
                     name='orders',
                ),
             ],
             axis=0,
         #Nº12
```

Проверим статистическую значимость различий в среднем количестве заказов на посетителя по «очищенным» данным.

Сформулируем гипотезы:

- Нулевая: различий в среднем количестве заказов между группами нет.
- Альтернативная: различия в среднем между группами есть.

```
In [31]: print('Значения p-value:', '{0:.3f}'.format(stats.mannwhitneyu(sampleAFiltered, sampleBF print('Различие в средних:', '{0:.3f}'.format(sampleBFiltered.mean()/sampleAFiltered.mea #№12

Значения p-value: 0.011
```

Вывод: По «очищенным» данным различий в среднем числе заказов групп A и B есть. Результаты по среднему количеству заказов практически не изменились.

Теперь проверим статистическую значимость различий в среднем чеке между группами по «очищенным» данным.

Сформулируем гипотезы:

Различие в средних: 0.158

- Нулевая: различий в среднем чеке между группами нет.
- Альтернативная: различия в среднем между группами есть.

```
In [32]: print('Значения p-value:',
            '{0:.3f}'.format(
                 stats.mannwhitneyu(
                    orders[
                         np.logical and(
                             orders['group'] == 'A',
                             np.logical not(orders['visitorId'].isin(abnormalUsers)),
                     ]['revenue'],
                     orders[
                         np.logical and(
                             orders['group'] == 'B',
                             np.logical not(orders['visitorId'].isin(abnormalUsers)),
                     ]['revenue'],
                 )[1]
             )
         print('Различие в средних:',
             "{0:.3f}".format(
                 orders[
                     np.logical and(
                         orders['group'] == 'B',
                         np.logical not(orders['visitorId'].isin(abnormalUsers)),
                 ]['revenue'].mean()
                 / orders[
                     np.logical and(
                         orders['group'] == 'A',
                         np.logical not(orders['visitorId'].isin(abnormalUsers)),
                 ['revenue'].mean()
                 - 1
         #№13
```

Различие в средних: 0.024

Вывод: Причин отвергать нулевую гипотезу и считать, что в среднем чеке есть различия, нет. P-value увеличелось, разница между сегментами сократилась с 25% до 2%.

Общие вывод.

Результаты исследования:

- При проведении теста лучше выбирать "Запустить акцию, дающую скидку на товар в день рождения"(при учете ICE) или "Добавить форму подписки на все основные страницы"(при учете RICE)
- Есть статистически значимые различия по среднему количеству заказов между группами по «сырым» и по данным после фильтрации аномалий;
- Нет статистически значимого различия по среднему чеку между группами ни по «сырым», ни по данным после фильтрации аномалий;
- График различия среднего чека колеблется. Сделать из этого графика определённые выводы нельзя;
- График различия среднего количества заказов на посетителя показывает, что результаты группы В лучше группы А;

По количеству заказов есть результат тут тест успешен, но по среднему чеку результатов нет. Вероятность, что продолжив наблюдения теста по среднему чеку между группами В может оказаться на самом деле лучше сегмента А мало вероятна, здесь тест можно признать неуспешным. Тест можно остановить группа В показала результат по увеличению количества заказов лучше чем группа А, тест можно признать успешным.