Изучение поведения пользователей мобильного приложения продаж продуктов питания

Задача — разобраться как ведут себя пользователи мобильного приложения. Изучите воронку продаж и после этого исследовать результаты А/А/В-эксперимента.

- Первый этап изучение общий информации.
- Второй этап предобработка данных.
- Третий этап изучение воронки событий.
- Четвертый этап изучение результатов эксперимента.
- Пятый этап общий вывод.

In [1]: import pandas as pd

Среди данных у нас есть — название события, уникальный идентификатор пользователя, время события, номер эксперимента.

Изучение общий информации.

```
import datetime as dt
from scipy import stats as st
import numpy as np
import matplotlib.pyplot as plt
from pandas.plotting import register_matplotlib_converters
import warnings
import scipy.stats as stats
import math as mth
import plotly.express as px
from plotly import graph_objects as go
In [2]:

try:
    data = pd.read_csv('/datasets/logs_exp.csv', sep='\t')
except:
    data = pd.read_csv('C:\\Users\\User\\Documents\\Phyton\\logs_exp.csv', sep='\t')
display(data.head(10))
```

	EventName	DeviceIDHash	EventTimestamp	Expld
0	MainScreenAppear	4575588528974610257	1564029816	246
1	MainScreenAppear	7416695313311560658	1564053102	246
2	PaymentScreenSuccessful	3518123091307005509	1564054127	248
3	CartScreenAppear	3518123091307005509	1564054127	248
4	PaymentScreenSuccessful	6217807653094995999	1564055322	248
5	CartScreenAppear	6217807653094995999	1564055323	248
6	OffersScreenAppear	8351860793733343758	1564066242	246
7	MainScreenAppear	5682100281902512875	1564085677	246
8	MainScreenAppear	1850981295691852772	1564086702	247

```
9
                                             1564112112
             MainScreenAppear 5407636962369102641
                                                       246
In [3]: | data.info()
      <class 'pandas.core.frame.DataFrame'>
      RangeIndex: 244126 entries, 0 to 244125
      Data columns (total 4 columns):
       # Column Non-Null Count
                                       Dtype
                        _____
          ----
       0 EventName 244126 non-null object
       1 DeviceIDHash 244126 non-null int64
          EventTimestamp 244126 non-null int64
       3 ExpId 244126 non-null int64
      dtypes: int64(3), object(1)
      memory usage: 7.5+ MB
      Пропусков нет, нужно изменить названия колонок для большего удобства и тип даты и времени.
      Предобработка данных.
      Подготовка данных
```

```
In [4]: data = data.rename(
          columns={'EventName' : 'event name', 'DeviceIDHash' : 'device id hash',
                   'EventTimestamp' : 'event timestamp', 'ExpId' : 'exp id'}
In [5]: print(data.isna().sum())
       print('Количество дубликатов:', data.duplicated().sum())
       event name
       device id hash
       event timestamp 0
       exp id
       dtype: int64
       Количество дубликатов: 413
In [6]: data = data.drop_duplicates().reset index()
       data = data.iloc[: , 1:]
In [7]: | print(data.info())
       print('Количество дубликатов:', data.duplicated().sum());
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 243713 entries, 0 to 243712
       Data columns (total 4 columns):
        # Column Non-Null Count Dtype
       --- ----
                           -----
        0 event_name 243713 non-null object
        1 device id hash 243713 non-null int64
        2 event timestamp 243713 non-null int64
        3 exp id
                           243713 non-null int64
       dtypes: int64(3), object(1)
       memory usage: 7.4+ MB
       None
       Количество дубликатов: 0
In [8]: data['event timestamp'] = data['event timestamp'].astype(int)
In [9]:
       data['event timestamp'] = pd.to datetime(data['event timestamp'], unit='s')
       data['event timestamp'].dtype;
```

```
In [10]: #print(data)

In [11]: #convert datetime column to just date
    data['date'] = pd.to_datetime(data['event_timestamp']).dt.date
```

```
event name
                                     device_id_hash
                                                      event_timestamp exp_id
                                                                                     date
             MainScreenAppear 4575588528974610257 2019-07-25 04:43:36
     0
                                                                          246 2019-07-25
     1
              MainScreenAppear 7416695313311560658 2019-07-25 11:11:42
                                                                          246 2019-07-25
     2 PaymentScreenSuccessful 3518123091307005509
                                                    2019-07-25 11:28:47
                                                                          248 2019-07-25
     3
              CartScreenAppear 3518123091307005509 2019-07-25 11:28:47
                                                                          248 2019-07-25
        PaymentScreenSuccessful 6217807653094995999 2019-07-25 11:48:42
                                                                          248 2019-07-25
243708
              MainScreenAppear 4599628364049201812 2019-08-07 21:12:25
                                                                          247 2019-08-07
243709
              MainScreenAppear 5849806612437486590 2019-08-07 21:13:59
                                                                          246 2019-08-07
243710
             MainScreenAppear 5746969938801999050 2019-08-07 21:14:43
                                                                          246 2019-08-07
243711
              MainScreenAppear 5746969938801999050 2019-08-07 21:14:58
                                                                          246 2019-08-07
243712
            OffersScreenAppear 5746969938801999050 2019-08-07 21:15:17
                                                                          246 2019-08-07
```

243713 rows × 5 columns

#data.info()

display(data)

```
In [12]: #создаем таблицу с группами и id пользователей intersections=data.pivot_table(index=['device_id_hash'], values='exp_id') #разбиваем их на отдельные таблицы по группам a246 = intersections.query('exp_id == 246').reset_index() a247 = intersections.query('exp_id == 247').reset_index() b248 = intersections.query('exp_id == 248').reset_index() #соеденяем чтобы у каждой группы были свои колонки с пользователями intersections_data = a246.merge(a247, on='exp_id', how='outer') intersections_data=intersections_data.merge(b248, on='exp_id', how='outer') #смотрим совпадения по столбцам s1 = intersections_data.query('device_id_hash == device_id_hash_y') s2 = intersections_data.query('device_id_hash == device_id_hash_x') s3 = intersections_data.query('device_id_hash_x == device_id_hash_y') display(s1, s2, s3);
```

```
device_id_hash_x exp_id device_id_hash_y device_id_hash

device_id_hash_x exp_id device_id_hash_y device_id_hash

device_id_hash_x exp_id device_id_hash_y device_id_hash
```

Пересечения пользователей в группах отсутствует.

Данные проверены на пропуски, изменены названия колонок, скорректирован тип данных даты и времени в event_timestamp. Создан отдельный столбец с датами date. Данные проверены и очищены от дубликатов.

Изучение и проверка данных

```
In [13]: print('Всего событий в логе:',len(data['event name']))
          #print(len(data['event name'].unique()))
         Всего событий в логе: 243713
In [14]: | print('Всего пользователей в логе:',len(data['device id hash'].unique()))
         Всего пользователей в логе: 7551
         data mean=data.pivot table(index=['device id hash'], values='event name', aggfunc='count
In [15]:
          print(data mean.describe())
         print('В среднем', int(243713/7551), 'события приходится на одного пользователя, медиана
                  event name
         count 7551.000000
                  32.275593
         mean
                  65.154219
         std
         min
                   1.000000
         25%
                   9.000000
         50%
                  20.000000
                  37.000000
         75%
         max 2307.000000
         В среднем 32 события приходится на одного пользователя, медиана равна 20.
         #2.2.4
In [16]:
         print('Максимальная дата:', data['date'].max())
         print('Минимальная дата:', data['date'].min())
          #data.hist(figsize=(10, 10)); 7
         Максимальная дата: 2019-08-07
         Минимальная дата: 2019-07-25
In [17]: data['event timestamp'].hist(figsize=(20, 5), bins=14)
         plt.title('Количество событий распределённых по дате и времени')
         plt.xlabel('Период проведения эксперимента')
         plt.ylabel('Количество событий')
         plt.show()
                                             Количество событий распределённых по дате и времени
          35000
          30000
         ₹ 25000
          20000
          15000
          10000
                                                    2019-07-31 2019-08-01
Период проведения эксперимента
              2019-07-25
                           2019-07-27
                                       2019-07-29
                                                                      2019-08-03
                                                                                   2019-08-05
                                                                                               2019-08-07
```

Данные не полные, в первую неделю число событий было очень мало, для изучения лучше взять вторую неделю с наибольшим количеством данных.

```
In [18]: data['date'] = data['date'].astype('datetime64')
    data_1 = data.query('date > "2019-07-31"')

In [19]: data_1.info()

    <class 'pandas.core.frame.DataFrame'>
        Int64Index: 240887 entries, 2826 to 243712
        Data columns (total 5 columns):
        # Column Non-Null Count Dtype
```

```
0 event name 240887 non-null object
         1 device id hash 240887 non-null int64
         2 event_timestamp 240887 non-null datetime64[ns]
         3 exp id 240887 non-null int64
         4 date
                            240887 non-null datetime64[ns]
        dtypes: datetime64[ns](2), int64(2), object(1)
        memory usage: 11.0+ MB
In [20]: print('Данных осталось:', (data_1['event_name'].count()*100/244126).round(2),'%')
        print('Данных удалили:', (100 - (data 1['event name'].count()*100/244126)).round(2),'%')
        print('Всего пользователей в логе осталось:',len(data 1['device id hash'].unique())))
        x = 100 - (7534 * 100 / 7551)
        print('Всего пользователей удалили: 0.2 %')
        Данных осталось: 98.67 %
        Данных удалили: 1.33 %
        Всего пользователей в логе осталось: 7534
        Всего пользователей удалили: 0.2 %
        Не полные данные и дубликаты событий и пользователей составляют менее 2% от начальных данных
        их можно удалить.
In [21]: #2.2.6 Проверьте, что у вас есть пользователи из всех трёх экспериментальных групп.
        groop = data 1.pivot table(index=['exp id'], values='device id hash', aggfunc='nunique')
        display(groop)
               device id hash
        exp id
          246
                      2484
          247
                     2513
          248
                      2537
        Изучение воронки событий.
In [22]: print('Количество событий в логах')
        print()
        print(data 1['event name'].value counts());
        Количество событий в логах
        MainScreenAppear
                                117328
        OffersScreenAppear
                                  46333
        CartScreenAppear
                                   42303
                                 33918
        PaymentScreenSuccessful
```

1005

event['share'] = (event['device id hash'] / 7419).round(2)

In [23]: #event = data.groupby('event_name')['device_id_hash'].nunique().sort values(ascending=Fa

event.style.set caption('Количество пользователей совершивших событие')

.sort values(by ='device id hash', ascending=False)

event = (data 1.pivot table(index=['event name'], values='device id hash', aggfunc='nuni

.set table styles([{'selector': 'caption', 'props': [('color', 'black'), ('font-size

Tutorial

Name: event name, dtype: int64

event['share'] = event['share'].round(2)

Out[24]: Количество пользователей совершивших событие

event_name		
MainScreenAppear	7419	1.000000
OffersScreenAppear	4593	0.620000
CartScreenAppear	3734	0.500000
PaymentScreenSuccessful	3539	0.480000
Tutorial	840	0.110000

device id hash

share

Out[26]: Количество пользователей совершивших событие

device_id_hash share share_by_steps(%)

e١	/ei	٦ŧ	na	me	

_		
MainScreenAppear	7419 1.000000	100.000000
OffersScreenAppear	4593 0.620000	61.900000
CartScreenAppear	3734 0.500000	81.300000
PaymentScreenSuccessful	3539 0.480000	94.800000

На втором этапе теряется около 38% пользователей, больше чем у остальных событий. Событие Tutorial не является частью воронки, он служит только как обучающее руководство по пользованию приложением и этот этап многие пользователи пропускают.

```
y = ["Payment Screen Successful", "Cart Screen Appear", "Offers Screen Appear", "Main Sc
x = [95, 81, 62, 100]
x max = 110
x min = 0
for idx, val in enumerate(x):
   plt.barh(y[idx], x[idx], left = idx-3)
plt.xlim(x min, x max)
plt.title('График воронки пользователей доходящих от первого события до оплаты на каждом
share data = dict(
   number=[100, 62, 50, 48],
    share=["Main Screen Appear", "Offers Screen Appear", "Cart Screen Appear", "Payment
fig = px.funnel(share data, x='number', y='share',
                title='Beskar Forging Services Inc.')
fig = px.funnel(share data, y='share', x='number',
                template="simple white",
                title='График воронки пользователей доходящих от первого события до опла
                labels={"Stage": ""})
fig.show()
print(3539 / 7419 * 100, '% пользователей доходит от первого события до оплаты.')
```

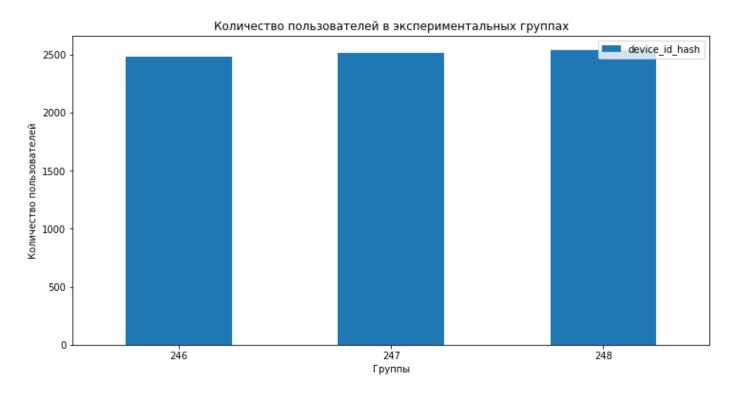
Вывод: От первого события до последнего доходит около 48% пользователей, при этом на втором

Изучение результатов эксперимента

```
In [29]: display(groop)
groop.plot(kind='bar', y='device_id_hash', figsize=(12, 6), rot = 0)
plt.title('Количество пользователей в экспериментальных группах')
plt.xlabel('Группы')
plt.ylabel('Количество пользователей')
plt.show()
```

device_id_hash

exp_id	
246	2484
247	2513
248	2537



Группы 246 и 247 являются контрольными, в 246 находятся 2484, а 247 около 2513 пользователей. В группе 248 пользователи использовавшие приложения с изменёнными шрифтами, в ней 2537 пользователей.

```
In [30]: print('Количество пользователей в различных группах различается не более чем на', int(25 Количество пользователей в различных группах различается не более чем на 1 %.
```

Out[31]: device_id_hash share event_name 2450 1.00 MainScreenAppear OffersScreenAppear 1542 0.63 0.52 CartScreenAppear 1266 **PaymentScreenSuccessful** 1200 0.49 **Tutorial** 278 0.11 In [32]: a2 = data_1.query('exp id == 247') event a2 = (a2.pivot table(index=['event name'], values='device id hash', aggfunc='nuniq .sort values(by ='device id hash', ascending=False) #event a2['share'] = (event a2['device id hash'] / event a2['device id hash'].sum()) event a2['share'] = (event a2['device id hash'] / 2476) event a2['share'] = event a2['share'].round(2) event a2 Out[32]: device_id_hash share event name

-		
MainScreenAppear	2476	1.00
OffersScreenAppear	1520	0.61
CartScreenAppear	1238	0.50
PaymentScreenSuccessful	1158	0.47
Tutorial	283	0.11

```
In [33]: b = data_1.query('exp id == 248')
         event b = (b.pivot table(index=['event name'], values='device id hash', aggfunc='nunique
                  .sort values(by ='device id hash', ascending=False)
         #event b['share'] = (event b['device id hash'] / event b['device id hash'].sum())
         event b['share'] = (event b['device id hash'] / 2493)
         event b['share'] = event b['share'].round(2)
         event b
```

Out[33]: device id hash share

event name 2493 1.00 MainScreenAppear OffersScreenAppear 1531 0.61 CartScreenAppear 1230 0.49 **PaymentScreenSuccessful** 1181 0.47 **Tutorial** 279 0.11

```
share event = pd.DataFrame(
In [34]:
         'event name': ['MainScreenAppear', 'OffersScreenAppear', 'CartScreenAppear', 'PaymentScre
         'share 246': [100, 63, 52, 49],
         'share 247': [100, 61, 50, 47],
```

Сравнение воронок пользователей в событиях по группам в %.

event_name share_246 share_247 share_248

MainScreenAppear	100	100	100
OffersScreenAppear	63	61	61
CartScreenAppear	52	50	49
PaymentScreenSuccessful	49	47	47

Вывод: При сравнении воронок групп можно сделать вывод что большой разницы между старыми и новыми шрифтами нет. В 246 контрольной группе на всех этапах есть 2% отличие от 247 контрольной группы и 248 экспериментальной, у 247 отличие от экспериментальной практически нет.

```
In [36]: def stat krit(msa1, x1, mas2, x2):
             alpha = 0.05 # критический уровень статистической значимости
             purchases = np.array([x1, x2])
            leads = np.array([msa1, mas2])
            p1 = purchases[0] / leads[0]
            p2= purchases[1] / leads[1]
            p combined = (purchases[0] + purchases[1]) / (leads[0] + leads[1])
            difference = p1 - p2
             z value = difference / mth.sqrt(p combined * (1 - p combined) * (1/leads[0] + 1/lead
            distr = st.norm(0, 1)
            p value = (1-distr.cdf(abs(z value))) * 2
            print('p-значение: ', p value)
             if p value < alpha:</pre>
                print('Отвергаем нулевую гипотезу: между долями есть значимая разница')
             else:
                print(
                     'Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разн
```

Сравниваем контрольные группы друг с другом, группу 246 с группой 247.

Сформулируем гипотезы:

• Нулевая: различий между контрольными группами 246 и 247 в событии Offers Screen Appear нет.

 Альтернативная: различия между контрольными группами 246 и 247 в событии Offers Screen Appear есть.

```
In [37]: #OffersScreenAppear
         stat krit(2450, 1542, 2476, 1520)
```

р-значение: 0.2622344959255778

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольными группами 246 и 247 в событии Cart Screen Appear нет.
- Альтернативная: различия между контрольными группами 246 и 247 в событии Cart Screen Appear есть.

```
In [38]: #CartScreenAppear
         stat krit(2450, 1266, 2476, 1238)
```

р-значение: 0.24012327015939383

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольными группами 246 и 247 в событии Payment Screen Successful
- Альтернативная: различия между контрольными группами 246 и 247 в событии Payment Screen Successful есть.

```
In [39]: #PaymentScreenSuccessful
         stat krit(2450, 1200, 2476, 1158)
```

р-значение: 0.12044299485641763

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

Вывод: Причин отвергать нулевую гипотезу и считать, что между контрольными группами 246 и 247 есть различия, нет.

Сравниваем контрольную группу 246 с исследуемой группой 248.

Сформулируем гипотезы:

- Нулевая: различий между контрольной группой 246 и исследуемой группой 248 в событии Offers Screen Appear нет.
- Альтернативная: различия между контрольной группой 246 и исследуемой группой 248 в событии Offers Screen Appear есть.

```
In [40]: #OffersScreenAppear
         stat krit(2493, 1531, 2450, 1542)
```

р-значение: 0.2684281587249231

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольной группой 246 и исследуемой группой 248 в событии Cart Screen Appear Het.
- Альтернативная: различия между контрольной группой 246 и исследуемой группой 248 в событии Cart Screen Appear есть.

```
In [41]: #CartScreenAppear
         stat krit(2493, 1266, 2450, 1230)
```

р-значение: 0.6844103115682585 Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольной группой 246 и исследуемой группой 248 в событии Payment Screen Successful нет.
- Альтернативная: различия между контрольной группой 246 и исследуемой группой 248 в событии Payment Screen Successful есть.

```
In [42]: #PaymentScreenSuccessful
         stat krit(2493, 1181, 2450, 1200)
```

р-значение: 0.2582638437556217

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

Вывод: Причин отвергать нулевую гипотезу и считать, что между контрольной группой 246 и исследуемой группой 248 есть различия, нет.

Сравниваем контрольную группу 247 с исследуемой группой 248.

Сформулируем гипотезы:

- Нулевая: различий между контрольной группой 247 и исследуемой группой 248 в событии Offers Screen Appear Het.
- Альтернативная: различия между контрольной группой 247 и исследуемой группой 248 в событии Offers Screen Appear есть

```
In [43]: #OffersScreenAppear
         stat krit(2493, 1531, 2476, 1520)
```

р-значение: 0.9869365252844515

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольной группой 247 и исследуемой группой 248 в событии Cart Screen Appear нет.
- Альтернативная: различия между контрольной группой 247 и исследуемой группой 248 в событии Cart Screen Appear есть.

```
In [44]: #CartScreenAppear
         stat krit(2493, 1230, 2476, 1238)
```

р-значение: 0.6408180183192491

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольной группой 247 и исследуемой группой 248 в событии Payment Screen Successful нет.
- Альтернативная: различия между контрольной группой 247 и исследуемой группой 248 в событии Payment Screen Successful есть.

```
In [45]: #PaymentScreenSuccessful
         stat krit(2493, 1181, 2476, 1158)
```

р-значение: 0.6699208079332859

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

Вывод: Причин отвергать нулевую гипотезу и считать, что между контрольной группой 247 и

исследуемой группой 248 есть различия, нет.

Сравниваем обобщённую контрольную группу с исследуемой группой.

Сформулируем гипотезы:

- Нулевая: различий между контрольной группой исследуемой группой в событии Offers Screen Appear нет.
- Альтернативная: различия между контрольной группой и исследуемой группой в событии Offers Screen Appear есть

```
In [46]: #OffersScreenAppear
stat_krit(2493, 1531, 4926, 3062)
```

р-значение: 0.5308589432077624

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольной группой и исследуемой группой в событии Cart Screen Appear нет.
- Альтернативная: различия между контрольной группой и исследуемой группой в событии Cart Screen Appear есть.

```
In [47]: #CartScreenAppear
stat_krit(2493, 1230, 4926, 2505)
```

р-значение: 0.21781510823139483

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

- Нулевая: различий между контрольной группой и исследуемой группой в событии Payment Screen Successful нет.
- Альтернативная: различия между контрольной группой и исследуемой группой в событии Payment Screen Successful есть.

```
In [48]: #PaymentScreenSuccessful
stat_krit(4926, 2358, 2493, 1181)
```

р-значение: 0.6863094718086811

Не получилось отвергнуть нулевую гипотезу, нет оснований считать доли разными

Вывод: Причин отвергать нулевую гипотезу и считать, что между объединенной контрольной группой и исследуемой группой есть различия, нет.

Было проведено 12 проверок статистических гипотез. При критерии в 5 % различий в полученных данных нет.

Критерий ниже 0.05 обычна используют в областях связанных с жизнью и здоровьем людей для

большей надежности, но тут можно упустить связь между явлениями, а взяв критерий больше наоборот можно найти закономерность там где ее нет, поэтому 0.05 наиболее подходящий критерий в данной ситуации.

Общий вывод.

По данным проведённых исследований можно подвести итоги:

- От главного экрана до экрана предложений доходят 62% пользователей, на этом этапе теряется наибольшее их количество 38%, на переходах к следующим этапов событий(экрана корзины и оплаты) теряется примерно по 12% пользователей. От начального количества пользователей приложением до оплаты остается 48%.
- Воронки контрольных и экспериментальной группы имеют не значительное различие на событии оплаты (Payment Screen Successful).
- Изменение шрифтов на потерю пользователей не влияет и при условии что есть свободные люди и ресурсы, а шрифты являются усторевшыми их можно заменить на новые, значимого влияния(положительного или отрицательного) на метрики эти изменения не окажут.

По итогу шрифты менять можно к потери покупателей продукта это не приведет.